

TRƯỜNG ĐẠI HỌC QUY NHƠN
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO
HỌC PHẦN: XỬ LÝ NGÔN NGỮ TỰ NHIÊN

CHỦ ĐỀ

Ứng dụng Mô hình Ngôn ngữ Lớn trong y tế (Med-LLMS)
Kết hợp kiến trúc RAG trong Hỗ trợ suy luận và chuẩn đoán bệnh

Giảng viên hướng dẫn: TS.LÊ QUANG HÙNG

Sinh viên thực hiện: NGUYỄN NGỌC NHƯ HIẾU

Mã số sinh viên: 4651050076

Ngành và khóa: CÔNG NGHỆ THÔNG TIN - K46

Gia Lai, tháng 6 năm 2025

LỜI CẢM ƠN

Kính gửi Thầy-Tiến sĩ Lê Quang Hùng,

Trước hết, em xin gửi lời cảm ơn chân thành đến TS. Lê Quang Hùng – giảng viên hướng dẫn học phần Xử lý ngôn ngữ tự nhiên, người đã tận tình giảng dạy, hướng dẫn và hỗ trợ em trong suốt quá trình thực hiện bài báo cáo với chủ đề “*Ứng dụng Mô hình Ngôn ngữ Lớn trong y tế (Med-LLMs) kết hợp kiến trúc RAG trong việc hỗ trợ suy luận và xác định bệnh*”. Những kiến thức, ý kiến đóng góp và sự hướng dẫn của thầy đã giúp em hoàn thành bài báo cáo này một cách tốt hơn.

Em cũng xin chân thành cảm ơn các thầy cô trong Khoa Công nghệ Thông tin đã truyền đạt cho em những kiến thức nền tảng quý báu trong suốt quá trình học tập tại trường. Những kiến thức đó là cơ sở quan trọng để em thực hiện và hoàn thành bài báo cáo học phần này.

Trong quá trình thực hiện báo cáo, mặc dù em đã cố gắng tìm hiểu, nghiên cứu và hoàn thiện nội dung, tuy nhiên do kiến thức và kinh nghiệm còn hạn chế nên bài báo cáo khó tránh khỏi những thiếu sót. Em rất mong nhận được sự góp ý và nhận xét từ thầy để bài báo cáo được hoàn thiện hơn.

Em xin trân trọng cảm ơn.

MỤC LỤC

LỜI CẢM ƠN	1
1. Giới thiệu đề tài.....	4
2. Xác định bài toán và mục tiêu	4
3. Phương pháp tiếp cận.....	5
3.1. Thu nhập và xử lý dữ liệu	5
3.2. Lựa chọn Mô hình và Xây dựng Hệ thống	6
3.3. Chiến lược đánh giá và cải thiện hệ thống.....	7
3.3.1. Đánh giá mô hình phân loại(BERT)	8
3.3.2. Đánh giá hệ thống truy xuất(FAISS)	8
3.3.3. Đánh giá tổng thể hệ thống chatbot	8
3.3.4. Chiến lược tối ưu hóa hệ thống.....	9
3.3.5. Hướng phát triển tương lai.....	9
4. Thực nghiệm	9
4.1. Bộ dữ liệu.....	9
4.2. Quy trình Tiền Xử lý dữ liệu.....	12
4.2.1. Làm sạch và lọc dữ liệu.....	12
4.2.2. Mã hóa nhãn(Label Encoding)	12
4.2.3. Chia tập dữ liệu huấn luyện và kiểm	12
4.2.4. Biểu diễn văn bản (Tokenization)	13
4.2.5. Chuẩn hóa dữ liệu (Dataset PyTorch).....	13
4.3. Xây dựng mô hình và hệ thống.....	14
4.3.1. Mô hình phân biệt BERT	14
4.3.2. Huấn luyện mô hình.....	15
4.3.3. Đánh giá mô hình.....	17

4.3.4. Hệ thống truy xuất FAISS.....	18
4.3.5. Xây dựng chatbot y tế	18
4.3.6. Hệ thống chatbot y tế	19
5. Phân tích ưu và nhược điểm của hệ thống BERT kết hợp FAISS	22
5.1. Ưu điểm của hệ thống.....	22
5.1.1. Tăng độ chính xác trong phân loại và truy xuất.....	22
5.1.2. Tối ưu hiệu suất và tài nguyên tính toán	23
5.1.3. Khả năng mở rộng và cập nhật dữ liệu.....	23
5.1.4. Cải thiện chất lượng câu trả lời	23
5.2. Nhược điểm và thách thức	23
5.2.1. Phụ thuộc vào chất lượng dữ liệu.....	23
5.2.2. Hạn chế của mô hình BERT	24
5.2.3. Hiệu quả truy xuất phụ thuộc FAISS	24
5.2.4. Thiếu khả năng sinh ngôn ngữ tự nhiên nâng cao	25
5.3. Bảng tổng kết đánh giá.....	25

1. Giới thiệu đề tài

Khối lượng lớn dữ liệu y tế được tạo ra trong những năm gần đây, bao gồm dữ liệu y khoa, hồ sơ bệnh án điện tử và các công trình nghiên cứu lâm sàng, đã đặt ra một thách thức lớn trong việc khai thác và ứng dụng tri thức y học vào thực tiễn khám chữa bệnh. Đặc biệt, trong quá trình chẩn đoán, các bác sĩ và nhân viên y tế phải xử lý một lượng lớn thông tin liên quan đến triệu chứng, tiền sử bệnh và kết quả cận lâm sàng, trong khi bệnh nhân thường gặp khó khăn trong việc mô tả chính xác tình trạng sức khỏe của mình cũng như tiếp cận các nguồn thông tin y khoa đáng tin cậy.

Trước thực tế đó, việc ứng dụng **Mô hình Ngôn ngữ Lớn (Large Language Models – LLMs)** trong hỗ trợ phỏng đoán và chẩn đoán bệnh dựa trên triệu chứng đang thu hút sự quan tâm ngày càng tăng. Với khả năng hiểu và xử lý ngôn ngữ tự nhiên, LLMs có thể tiếp nhận các mô tả triệu chứng do bệnh nhân cung cấp, phân tích mối liên hệ giữa các biểu hiện lâm sàng, từ đó đưa ra các phỏng đoán ban đầu về những bệnh lý có khả năng liên quan.

Đề tài này tập trung nghiên cứu và phát triển một hệ thống thông minh dựa trên mô hình ngôn ngữ lớn, cho phép thu thập và phân tích thông tin triệu chứng của bệnh nhân nhằm hỗ trợ quá trình chẩn đoán bệnh. Thay vì thay thế vai trò của bác sĩ, hệ thống được định hướng như một công cụ hỗ trợ ra quyết định, giúp gợi ý các khả năng bệnh lý tiềm năng, cung cấp thông tin tham khảo và góp phần giảm tải áp lực trong giai đoạn thăm khám ban đầu.

Phạm vi nghiên cứu của đề tài giới hạn ở việc xây dựng một mô hình có khả năng ánh xạ từ tập hợp các triệu chứng đầu vào sang các chẩn đoán bệnh có xác suất cao, dựa trên tri thức y khoa đã được huấn luyện và tinh chỉnh. Hệ thống hướng tới việc phục vụ cả nhân viên y tế trong công tác hỗ trợ chẩn đoán sơ bộ và bệnh nhân trong việc hiểu rõ hơn về tình trạng sức khỏe của bản thân, từ đó nâng cao hiệu quả và chất lượng chăm sóc y tế.

2. Xác định bài toán và mục tiêu

- **Vấn đề cần giải quyết:** Khối lượng lớn dữ liệu trong y tế hiện nay, triệu chứng, tiền sử bệnh và tài liệu nghiên cứu khiến các bác sĩ gặp khó khăn trong việc tổng hợp và đưa

ra chẩn đoán nhanh chóng, đặc biệt ở giai đoạn thăm khám ban đầu. Trong khi đó bệnh, bệnh nhân thường mô tả triệu chứng bằng ngôn ngữ tự nhiên, thiếu chính xác hoặc không đầy đủ, gây khó khăn trong việc phân tích và chuẩn đoán bệnh. Nhu cầu cần thiết xây dựng một hệ thống thông minh có khả năng hỗ trợ phỏng đoán và chẩn đoán bệnh dựa trên các triệu chứng của bệnh nhân.

- Mục tiêu của đề tài: Dựa trên các vấn đề đã xác định, đề tài đặt ra các mục tiêu cụ thể như sau:

1. Xây dựng hệ thống nhập triệu chứng cho phép bệnh nhân mô tả triệu chứng bằng ngôn ngữ tự nhiên và chuẩn hóa dữ liệu đầu vào để phục vụ phân tích
2. Phát triển mô hình Med-LLMs cho suy luận bệnh lý như phân tích mối quan hệ giữa triệu chứng, tiền sử bệnh và dữ liệu cận lâm sàng. Gợi ý các bệnh lý tiềm năng với xác suất cao
3. Hỗ trợ bác sĩ trong chuẩn đoán sơ bộ có thể đưa ra danh sách bệnh lý có khả năng liên quan và cung cấp thông tin tham khảo về đặc điểm bệnh và hướng xử trí ban đầu
4. Hỗ trợ bệnh nhân hiểu rõ tình trạng sức khỏe giúp bệnh nhân tiếp cận thông tin y khoa đáng tin cậy và nâng cao nhận thức và khả năng tự theo dõi sức khỏe.

3. Phương pháp tiếp cận

Để xây dựng hệ thống chatbot y tế, đề tài áp dụng một phương pháp tiếp cận có hệ thống, bao gồm ba giai đoạn chính: (1) Thu thập và xử lý dữ liệu, (2) Lựa chọn mô hình và xây dựng hệ thống, và (3) Đánh giá và tối ưu hóa mô hình. Quy trình này đảm bảo tính logic, hiệu quả và khả năng áp dụng thực tiễn của hệ thống.

3.1. Thu nhập và xử lý dữ liệu

Dữ liệu đầu vào đóng vai trò quan trọng trong việc quyết định hiệu suất của hệ thống. Dữ liệu được sử dụng trong đề tài là bộ dữ liệu MedQuAD, bao gồm các cặp câu hỏi – câu trả lời trong lĩnh vực y tế.

Hạng mục	Chi tiết
Nguồn dữ liệu	Bộ dữ liệu MedQuAD (Medical Question Answering)

	Dataset)
Nội dung	Bao gồm question, answer, focus_area
Đặc điểm	Dữ liệu dạng hỏi – đáp y tế, có phân loại theo nhóm bệnh

Quy trình tiền xử lý dữ liệu

1. Làm sạch dữ liệu

Loại bỏ các bản ghi thiếu dữ liệu, chỉ giữ lại các trường quan trọng gồm question, answer và focus_area.

2. Lọc dữ liệu

Chỉ giữ lại Top 100 nhóm bệnh phổ biến nhất nhằm giảm nhiễu và tăng độ ổn định cho mô hình.

3. Mã hóa nhãn (Label Encoding)

Chuyển đổi các nhãn dạng văn bản (*focus_area*) thành dạng số để phục vụ cho mô hình học máy.

4. Chia tập dữ liệu

Dữ liệu được chia thành tập huấn luyện (80%) và tập kiểm tra (20%) sử dụng phương pháp phân tầng nhằm đảm bảo phân bố đồng đều giữa các lớp.

5. Biểu diễn văn bản (Tokenization)

Sử dụng tokenizer của mô hình BERT để chuyển đổi câu hỏi thành dạng token và tensor số.

6. Biểu diễn vector (Embedding)

Sử dụng mô hình embedding để chuyển câu hỏi thành vector ngữ nghĩa, phục vụ cho hệ thống truy xuất FAISS.

3.2. Lựa chọn Mô hình và Xây dựng Hệ thống

Chọn mô hình phù hợp đóng vai trò quan trọng trong việc đảm bảo hiệu quả của hệ thống chatbot. Đề tài sử dụng mô hình học sâu kết hợp với truy xuất thông tin để nâng cao độ chính xác.

Mô hình phân loại:

Hệ thống sử dụng mô hình BERT đã được pretrained và tiến hành fine-tune cho bài toán phân loại đa lớp trong lĩnh vực y tế.

Mô hình có nhiệm vụ:

- Nhận đầu vào là câu hỏi y tế
- Dự đoán nhóm bệnh tương ứng (focus_area)

Hệ thống truy xuất thông tin:

Để cải thiện chất lượng câu trả lời, hệ thống sử dụng FAISS làm cơ chế tìm kiếm ngữ nghĩa.

- Các câu hỏi trong dữ liệu được chuyển thành vector embedding
- Các vector này được lưu trữ trong FAISS
- Khi có truy vấn mới, hệ thống tìm các câu hỏi tương tự dựa trên độ gần vector

Quy trình hoạt động của hệ thống

Hệ thống chatbot hoạt động theo các bước:

1. Người dùng nhập câu hỏi y tế
2. Câu hỏi được tiền xử lý và token hóa
3. Mô hình BERT dự đoán nhóm bệnh
4. Chuyển nhãn số sang tên bệnh
5. Truy vấn được chuyển thành vector embedding
6. FAISS tìm các câu hỏi tương tự
7. Lọc kết quả theo nhóm bệnh
8. Trả kết quả cho người dùng

3.3. Chiến lược đánh giá và cải thiện hệ thống

Đánh giá và tối ưu hóa hệ thống đóng vai trò quan trọng nhằm đảm bảo độ chính xác, tính tin cậy và khả năng ứng dụng thực tiễn. Hệ thống được đánh giá trên cả hai

thành phần chính: mô hình phân loại BERT và hệ thống truy xuất thông tin FAISS. Việc kết hợp đánh giá hai thành phần này giúp đảm bảo hệ thống không chỉ dự đoán đúng nhóm bệnh mà còn cung cấp thông tin phù hợp và hữu ích cho người dùng.

3.3.1. Đánh giá mô hình phân loại(BERT)

Mô hình BERT được đánh giá thông qua tập dữ liệu kiểm tra (test set) đã được tách riêng trong quá trình huấn luyện, chỉ số chính được sử dụng là:

- Độ chính xác: đo tỷ lệ số dự đoán đúng trên tổng số mẫu kiểm tra. Đây là chỉ số cơ bản phản ánh khả năng phân loại của mô hình.

Trong các trường hợp cần đánh giá chi tiết hơn, có thể sử dụng thêm các chỉ số như:

- Precision: đo mức độ chính xác của các dự đoán dương tính
- Recall: đo khả năng phát hiện đầy đủ các mẫu thuộc một lớp
- F1-score: trung bình điều hòa giữa Precision và Recall

3.3.2. Đánh giá hệ thống truy xuất(FAISS)

Hệ thống FAISS, việc đánh giá tập trung vào khả năng tìm kiếm các câu hỏi và câu trả lời có nội dung tương đồng với truy vấn đầu vào. Các tiêu chí đánh giá bao gồm:

- Độ liên quan: mức độ phù hợp giữa câu trả lời được truy xuất và câu hỏi của người dùng.
- Độ chính xác ngữ nghĩa: khả năng hệ thống tìm ra các nội dung có ý nghĩa tương tự, không chỉ dựa trên từ khóa mà còn dựa trên ngữ cảnh.
- Chất lượng nội dung trả về: câu trả lời cần đầy đủ, rõ ràng và không chứa thông tin sai lệch hoặc nhiễu.

3.3.3. Đánh giá tổng thể hệ thống chatbot

Hệ thống chatbot được đánh giá dựa trên khả năng phối hợp giữa hai thành phần chính (BERT và FAISS). Một hệ thống hiệu quả cần đảm bảo:

- Dự đoán đúng nhóm bệnh từ câu hỏi đầu vào
- Truy xuất được thông tin phù hợp với nhóm bệnh đã dự đoán
- Cung cấp câu trả lời rõ ràng, dễ hiểu và có giá trị tham khảo

Ngoài ra, trải nghiệm người dùng cũng là một yếu tố quan trọng, bao gồm:

- Tốc độ phản hồi của hệ thống
- Tính dễ hiểu của câu trả lời
- Mức độ hữu ích của thông tin cung cấp

3.3.4. Chiến lược tối ưu hóa hệ thống

Để nâng cao hiệu suất của hệ thống, một số hướng tối ưu hóa được đề xuất như sau:

- Cải thiện dữ liệu đầu vào: Tăng số lượng dữ liệu huấn luyện, làm sạch dữ liệu kỹ hơn và cân bằng dữ liệu giữa các nhóm bệnh.
- Tối ưu mô hình BERT: Điều chỉnh các siêu tham số như learning rate, batch size, số epoch hoặc áp dụng fine-tuning sâu hơn để cải thiện khả năng phân loại.
- Tối ưu hệ thống FAISS: Điều chỉnh số lượng kết quả truy xuất (k), lựa chọn phương pháp chuẩn hóa vector phù hợp và cải thiện chất lượng embedding.
- Cải thiện bước lọc kết quả: Xây dựng các tiêu chí lọc chặt chẽ hơn nhằm loại bỏ các câu trả lời không liên quan hoặc chứa thông tin không chính xác.

3.3.5. Hướng phát triển tương lai

Trong tương lai, hệ thống có thể được mở rộng theo các hướng:

- Tích hợp thêm nhiều nguồn dữ liệu y tế uy tín
- Áp dụng các mô hình mạnh hơn như BioBERT hoặc các mô hình ngôn ngữ lớn
- Xây dựng giao diện người dùng thân thiện hơn
- Tối ưu hóa thời gian phản hồi và khả năng mở rộng hệ thống

4. Thực nghiệm

4.1. Bộ dữ liệu

Bộ dữ liệu được sử dụng trong hệ thống chatbot y tế là tập dữ liệu MedQuAD từ Kaggle bao gồm tổng cộng 16413 dòng dữ liệu. Được thu thập từ nhiều nguồn dữ liệu

y tế uy tín. Bao gồm các cặp câu hỏi – câu trả lời trong y tế, phục vụ cho bài toán phân loại và truy xuất thông tin y tế.

Sau đó quá trình thu nhập và tiền xử lý, dữ liệu được tổ chức thành các trường thông tin chính gồm: question (câu hỏi), answer (câu trả lời), focus_area (nhóm bệnh). Đây là các thành phần quan trọng phục vụ cho cả mô hình phân loại BERT và hệ thống truy xuất FAISS.

Để đảm bảo chất lượng dữ liệu và giảm độ nhiễu trong quá trình huấn luyện, hệ thống đã thực hiện lọc và giữ lại 100 nhóm bệnh phổ biến nhất (Top 100 classes) dựa trên tần suất xuất hiện

Bộ dữ liệu sau khi xử lý được chia thành hai tập chính gồm tập huấn luyện (training set) và tập kiểm tra (test set) theo tỷ lệ 80/20. Việc phân chia này giúp đảm bảo mô hình được học trên tập dữ liệu đủ lớn và được đánh giá trên dữ liệu chưa từng thấy, từ đó tăng độ tin cậy của kết quả.

Các mẫu dữ liệu trong bộ MedQuAD có cấu trúc rõ ràng, trong đó mỗi câu hỏi y tế được gắn với một nhóm bệnh cụ thể (focus_area). Điều này giúp mô hình học được mối quan hệ giữa ngôn ngữ tự nhiên và các khái niệm y khoa, phục vụ cho bài toán phân loại đa lớp.


Bên cạnh đó, bộ dữ liệu còn đóng vai trò quan trọng trong hệ thống truy xuất thông tin FAISS, nơi các câu hỏi và câu trả lời được chuyển thành vector để tìm kiếm theo độ tương đồng ngữ nghĩa. Nhờ vậy, hệ thống không chỉ dự đoán bệnh mà còn có khả năng cung cấp thông tin giải thích phù hợp cho người dùng.

Tải bộ dữ liệu tại:

[MedQuAD: Medical Question-Answer Dataset](#)

J279																
	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	
262	How to di	The only d	NIHSenior	Alzheimer's Disease												
263	How to di	An early, e	NIHSenior	Alzheimer's Disease												
264	How to di	The time f	NIHSenior	Alzheimer's Disease												
265	What are	Currently,	NIHSenior	Alzheimer's Disease												
266	How to pr	Currently,	NIHSenior	Alzheimer's Disease												
267	How to pr	Research	NIHSenior	Alzheimer's Disease												
268	How to pr	A number	NIHSenior	Alzheimer's Disease												
269	How to pr	Keeping th	NIHSenior	Alzheimer's Disease												
270	what rese	Basic rese	NIHSenior	Alzheimer's Disease												
271	what rese	Translatio	NIHSenior	Alzheimer's Disease												
272	what rese	Clinical re	NIHSenior	Alzheimer's Disease												
273	What are	People wi	NIHSenior	Alzheimer's Disease												
274	What is (a	An Inflam	NIHSenior	Rheumatoid Arthritis												
275	What cau	Actual Cai	NIHSenior	Rheumatoid Arthritis												
276	What are	Swelling a	NIHSenior	Rheumatoid Arthritis												
277	What are	Most Sym	NIHSenior	Rheumatoid Arthritis												
278	what rese	Scientists	NIHSenior	Rheumatoid Arthritis												
279	What is (a	Rheumato	NIHSenior	Rheumatoid Arthritis												
280	What cau	Scientists	NIHSenior	Rheumatoid Arthritis												
281	What are	Rheumato	NIHSenior	Rheumatoid Arthritis												
282	How to di	Rheumato	NIHSenior	Rheumatoid Arthritis												
283	How to di	There is n	NIHSenior	Rheumatoid Arthritis												
284	What are	Medicatio	NIHSenior	Rheumatoid Arthritis												
285	What are	Most peo	NIHSenior	Rheumatoid Arthritis												
286	What is (a	Rest. Peo	NIHSenior	Rheumatoid Arthritis												
287	What is (a	Hearing lc	NIHSenior	Hearing Loss												
288	How to pr	Causes of	NIHSenior	Hearing Loss												
289	What are	Don't Ignc	NIHSenior	Hearing Loss												
290	What are	Your doct	NIHSenior	Hearing Loss												
291	How many	Approxim	NIHSenior	Hearing Loss												
292	What is (a	Presbycus	NIHSenior	Hearing Loss												
293	What cau	Hearing lc	NIHSenior	Hearing Loss												
294	How to pr	Washing v	NIHSenior	Hearing Loss												

Hình 1 Tập dữ liệu



Hình 2 Biểu đồ phân bố dữ liệu

4.2. Quy trình Tiền Xử lý dữ liệu

4.2.1. Làm sạch và lọc dữ liệu

Dữ liệu lúc đầu được xử lý nhằm bỏ các bản ghi không hợp lệ như loại bỏ các giá trị trống(missing values), lọc các nhóm bệnh phổ biến nhất(Top 100 classes), loại bỏ dữ liệu không cần thiết chỉ giữ lại các trường quang trọng. Để tăng chất lượng dữ liệu và làm giảm nhiễu trong quá trình huấn luyện mô hình.

```
import torch
import pandas as pd
from sklearn.model_selection import train_test_split
from transformers import AutoTokenizer, AutoModelForSequenceClassification, TrainingArguments, Trainer

du_lieu = pd.read_csv("medquad.csv")
du_lieu = du_lieu[['question', 'answer', 'focus_area']].dropna()

# chỉ lấy 100 loại bệnh phổ biến
TOP_N_CLASSES = 100
# lấy 100 nhóm bệnh xuất hiện nhiều nhất
top_focus_areas = du_lieu['focus_area'].value_counts().nlargest(TOP_N_CLASSES).index.tolist()
#Lọc dữ liệu giữ lại dl thuộc 100 nhóm đó
du_lieu_filtered = du_lieu[du_lieu['focus_area'].isin(top_focus_areas)].copy()
```

4.2.2. Mã hóa nhãn(Label Encoding)

Dữ liệu nhãn ban đầu ở dạng chuỗi (text), hệ thống thực hiện chuyển đổi sang dạng số bằng phương pháp factorization. Mỗi nhóm bệnh được ánh xạ thành một giá trị số tương ứng.

```
# tạo labels số
du_lieu_filtered['label'], labels = pd.factorize(du_lieu_filtered['focus_area'])
# đếm có bao nhiêu loại bệnh
so_lop = len(labels)
```

4.2.3. Chia tập dữ liệu huấn luyện và kiểm

Dữ liệu sau khi xử lý được chia thành hai tập chính gồm tập huấn luyện (training set) chiếm 80% và tập kiểm tra (test set) chiếm 20%. Kỹ thuật phân tầng (stratified

sampling) được sử dụng nhằm đảm bảo phân bố đồng đều của các lớp dữ liệu giữa hai tập, giúp mô hình tranh tình trạng mất cân bằng dữ liệu và cải thiện độ tin cậy khi đánh giá.

```
# chia train /test
train_df, test_df = train_test_split(
    du_lieu_filtered,
    test_size=0.2,
    random_state=42,
    stratify=du_lieu_filtered['label']
)
```

4.2.4. Biểu diễn văn bản (Tokenization)

Câu hỏi y tế được xử lý thông qua tokenizer của mô hình BERT. Quá trình này bao gồm việc chuyển đổi văn bản thành chuỗi token, chuẩn hóa độ dài về 128 token thông qua padding và truncation, đồng thời chuyển dữ liệu sang dạng tensor để phù hợp với đầu vào của mô hình học sâu. Đây là bước quan trọng giúp chuyển đổi dữ liệu văn bản sang dạng số mà mô hình có thể xử lý.

```
encoding = tokenizer(
    self.cau_hoi[idx],
    # chuẩn hóa độ dài câu ngắn -> thêm số 0 câu dài cắt bớt
    padding='max_length',
    truncation=True,
    max_length=128,
    return_tensors='pt'
)
```

4.2.5. Chuẩn hóa dữ liệu (Dataset PyTorch)

Nhằm tổ chức và biểu diễn dữ liệu câu hỏi và nhãn bệnh dưới dạng tensor, phục vụ cho quá trình huấn luyện mô hình học sâu.

```

▶ def __init__(self, df):
    self.cau_hoi = df['question'].tolist()
    self.nhan = df['label'].tolist()

    def __len__(self):
        return len(self.cau_hoi)

    def __getitem__(self, idx):
        encoding = tokenizer(
            self.cau_hoi[idx],
            padding='max_length',
            truncation=True,
            max_length=128,
            return_tensors='pt'
        )

        item = {k: v.squeeze() for k, v in encoding.items()}
        item['labels'] = torch.tensor(self.nhan[idx])
        return item

train_ds = DatasetYTe(train_df)
test_ds = DatasetYTe(test_df)

```

4.3. Xây dựng mô hình và hệ thống

4.3.1. Mô hình phân biệt BERT

Sử dụng mô hình BERT pretrained (bert-base-uncased) và tiến hành fine-tune cho bài toán phân loại đa lớp trong lĩnh vực y tế. Mô hình được thiết kế nhằm dự đoán nhóm bệnh tương ứng dựa trên câu hỏi đầu vào của người dùng, từ đó đóng vai trò là thành phần chính trong việc hiểu ngữ nghĩa câu hỏi.

```

▶ #tải mô hình BERT và tokenizer từ Hugging Face, chuẩn bị cho bài toán phân loại
from transformers import AutoTokenizer, AutoModelForSequenceClassification
model_name = "bert-base-uncased" #uncased không phân biệt chữ hoa/thường
tokenizer = AutoTokenizer.from_pretrained(model_name)
#Tải BERT đã học sẵn, thêm lớp cuối để phân loại
model = AutoModelForSequenceClassification.from_pretrained(
    model_name,
    num_labels=so_lop
)

```

Kết quả

```

... /usr/local/lib/python3.12/dist-packages/huggingface_hub/utils/_auth.py:93: UserWarning:
The secret `HF_TOKEN` does not exist in your Colab secrets.
To authenticate with the Hugging Face Hub, create a token in your settings tab (https://huggingface.co/settings/tokens), set it as secret in your Google Colab and restart yo
You will be able to reuse this secret in all of your notebooks.
Please note that authentication is recommended but still optional to access public models or datasets.
warnings.warn(
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
WARNING:huggingface_hub.utils._http:Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.

config.json: 100% ██████████ 570/570 [00:00<00:00, 26.2kB/s]

tokenizer_config.json: 100% ██████████ 48.0/48.0 [00:00<00:00, 3.13kB/s]

vocab.txt: ██████████ 232k/? [00:00<00:00, 2.28MB/s]

tokenizer.json: ██████████ 466k/? [00:00<00:00, 2.89MB/s]

model.safetensors: 100% ██████████ 440M/440M [00:02<00:00, 289MB/s]

Loading weights: 100% ██████████ 199/199 [00:00<00:00, 524.52it/s, Materializing param=bert.pooler.dense.weight]
BertForSequenceClassification LOAD REPORT from: bert-base-uncased
Key | Status |
-----+-----+
cls.predictions.bias | UNEXPECTED |
cls.predictions.transform.LayerNorm.weight | UNEXPECTED |
cls.predictions.transform.dense.weight | UNEXPECTED |

cls.seq_relationship.bias | UNEXPECTED |
cls.seq_relationship.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.bias | UNEXPECTED |
classifier.weight | MISSING |
classifier.bias | MISSING |

Notes:
- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect identical arch.
- MISSING :those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.

```

4.3.2. Huấn luyện mô hình

Mô hình được huấn luyện bằng thư viện Trainer của Hugging Face với các tham số như learning rate $2e-5$, batch size 8 và số epoch bằng 3. Quá trình huấn luyện giúp mô hình học được mối quan hệ giữa câu hỏi và nhóm bệnh tương ứng, đồng thời tối ưu hóa khả năng phân loại.

```
▶ # cấu hình máy học
args = TrainingArguments(
    # lưu model sau khi train
    output_dir="./model_bert",
    #ttooocs độ học
    learning_rate=2e-5,
    # mỗi lần học 8 câu
    per_device_train_batch_size=8,
    #khi test cũng 8c/lần
    per_device_eval_batch_size=8,
    # học toannf bộ dữ liệu 3 lần
    num_train_epochs=3,
    #mỗi lần học xong 1 vòng → test 1 lần
    eval_strategy="epoch",
    #mỗi vòng học xong → lưu model 1 lần
    save_strategy="epoch",
    report_to="none"
)
# máy huấn luyện
trainer = Trainer(
    model=model,
    args=args,
    train_dataset=train_ds,
    eval_dataset=test_ds
)

trainer.train()
```

Kết quả sau khi huấn luyện và train mô hình

```

... Number of classes after filtering: 100
Loading weights: 100% [Progress bar] 199/199 [00:00<00:00, 380.59it/s, Materializing param=bert.pooler.dense.weight]
BertForSequenceClassification LOAD REPORT from: bert-base-uncased
Key | Status |
-----|-----|
cls.predictions.bias | UNEXPECTED |
cls.predictions.transform.LayerNorm.weight | UNEXPECTED |
cls.predictions.transform.dense.weight | UNEXPECTED |
cls.predictions.transform.dense.bias | UNEXPECTED |
cls.seq_relationship.bias | UNEXPECTED |
cls.seq_relationship.weight | UNEXPECTED |
cls.predictions.transform.LayerNorm.bias | UNEXPECTED |
classifier.weight | MISSING |
classifier.bias | MISSING |

Notes:
- UNEXPECTED :can be ignored when loading from different task/architecture; not ok if you expect identical arch.
- MISSING :those params were newly initialized because missing from the checkpoint. Consider training on your downstream task.
[468/468 02:21, Epoch 3/3]

Epoch Training Loss Validation Loss
1 No log 3.881045
2 No log 3.255625
3 No log 3.033979

Writing model shards: 100% [Progress bar] 1/1 [00:02<00:00, 2.12s/it]
Writing model shards: 100% [Progress bar] 1/1 [00:07<00:00, 7.22s/it]
Writing model shards: 100% [Progress bar] 1/1 [00:10<00:00, 10.41s/it]
TrainOutput(global_step=468, training_loss=3.791359143379407, metrics={'train_runtime': 143.0125, 'train_samples_per_second': 26.096, 'train_steps_per_second': 3.272,
'total_flos': 245698615406592.0, 'train_loss': 3.791359143379407, 'epoch': 3.0})

```

4.3.3. Đánh giá mô hình

Hiệu suất của mô hình được đánh giá thông qua chỉ số độ chính xác (Accuracy), bằng cách so sánh kết quả dự đoán của mô hình với nhãn thực tế trên tập dữ liệu kiểm tra. Kết quả này phản ánh mức độ hiệu quả của mô hình trong bài toán phân loại y tế.

```

▶ import numpy as np
from sklearn.metrics import accuracy_score
#model dự đoán(predict → lấy dự đoán)
pred = trainer.predict(test_ds)
# lấy kq dự đoán (argmax → chọn nhãn)
y_pred = np.argmax(pred.predictions, axis=1)
# lấy đáp án đúng
y_true = test_df['label'].values
# tính độ chính xác(accuracy → đo độ đúng)
print("Accuracy:", accuracy_score(y_true, y_pred))

```

Kết quả sau khi đánh giá mô hình

```

... Accuracy: 0.77491961414791

```

4.3.4. Hệ thống truy xuất FAISS

Sử dụng FAISS (Facebook AI Similarity Search) để tìm kiếm các câu hỏi có nội dung tương tự trong cơ sở dữ liệu. Các câu hỏi được chuyển thành vector embedding và lưu trữ trong chỉ mục FAISS, cho phép tìm kiếm nhanh các câu trả lời liên quan dựa trên độ tương đồng ngữ nghĩa.



```
def lay_giai_thich(query,benh,k=10):
    query_vec = embedder.encode([query]).astype("float32")
    faiss.normalize_L2(query_vec)

    D, I = index.search(query_vec, k)

    ket_qua = []
    for i in I[0]:
        q = du_lieu.iloc[i]["question"]
        a = du_lieu.iloc[i]["answer"]
        focus = du_lieu.iloc[i]["focus_area"]

        # lọc bệnh khác
        if focus != benh:
            continue

        # lọc rác
        if len(a) < 100:
            continue
        if "@" in a or "www" in a:
            continue

        ket_qua.append(a)

    return ket_qua[:2]
```

4.3.5. Xây dựng chatbot y tế

Hệ thống chatbot được xây dựng theo mô hình kết hợp giữa phân loại và truy xuất thông tin. Cụ thể, BERT được sử dụng để dự đoán nhóm bệnh từ câu hỏi đầu vào, sau đó FAISS được sử dụng để tìm kiếm các câu trả lời phù hợp trong cơ sở dữ liệu. Kết quả cuối cùng bao gồm cả dự đoán bệnh và phần giải thích tương ứng, giúp hệ thống vừa có khả năng nhận diện bệnh vừa cung cấp thông tin hỗ trợ người dùng.

```
def chatbot_y_te(trieu_chung):
    # bước 1: đoán bệnh
   benh = du_doan_benh(trieu_chung)
    # bước 2: lấy giải thích
   giai_thich = lay_giai_thich(trieu_chung, benh)
    # format output
    print("\n=== KẾT QUẢ ===")
    print("Triệu chứng:", trieu_chung)
    print("👉 Bệnh dự đoán:", benh)

    print("\n👉 Giải thích:")
    for gt in giai_thich:
        print("\n-", gt)
```

Kết quả sau khi hoàn thiện chatbot y tế

```
v ""
=== KẾT QUẢ ===
Triệu chứng: what is diabetes
👉 Bệnh dự đoán: Diabetes

👉 Giải thích:

- Diabetes is a disease in which your blood glucose, or blood sugar, levels are too high. Glucose comes from the foods you eat. Insulin is a hormone that helps the glucose g
- People with diabetes should - do aerobic activities, such as brisk walking, which use the bodys large muscles to make the heart beat faster. The large muscles are those o
```

4.3.6. Hệ thống chatbot y tế

Sau khi hoàn tất quá trình huấn luyện mô hình BERT và xây dựng hệ thống truy xuất FAISS, hệ thống chatbot y tế được thiết kế để tiếp nhận câu hỏi từ người dùng và tạo ra câu trả lời phù hợp. Quy trình các bước cụ thể như sau:

Bước 1: Nhập câu hỏi từ người dùng

Người dùng nhập câu hỏi hoặc mô tả triệu chứng liên quan đến y tế bằng ngôn ngữ tự nhiên

Bước 2: Tiền xử lý và mã hóa văn bản (Tokenization)

Câu hỏi đầu vào được chuẩn hóa và chuyển đổi thành dạng token thông qua tokenizer của mô hình BERT.

Bước 3: Phân loại nhóm bệnh bằng mô hình BERT

Dữ liệu đã được mã hóa được đưa vào mô hình BERT đã được fine-tune. Mô hình thực hiện phân loại và dự đoán nhóm bệnh tương ứng dựa trên nội dung câu hỏi đầu vào.

Bước 4: Chuyển đổi nhãn dự đoán sang tên bệnh

Mô hình sẽ được chuyển ngược lại thành tên bệnh tương ứng dựa trên bảng mã hóa nhãn đã tạo trong quá trình huấn luyện.

Bước 5: Biểu diễn truy vấn và tìm kiếm tương tự (Embedding + FAISS)

Câu hỏi đầu vào được chuyển thành vector embedding và sử dụng hệ thống FAISS để tìm kiếm các câu hỏi có nội dung tương tự trong cơ sở dữ liệu y tế.

Bước 6: Lọc kết quả theo nhóm bệnh dự đoán


Câu trả lời được trích xuất từ FAISS sẽ được lọc theo đúng nhóm bệnh mà mô hình BERT đã dự đoán nhằm đảm bảo tính chính xác của thông tin.

Bước 7: Trích xuất câu trả lời phù hợp


Hệ thống chọn ra các câu trả lời có độ liên quan cao nhất, đồng thời loại bỏ các dữ liệu nhiễu hoặc không phù hợp.

Bước 8: Hiển thị kết quả cho người dùng

Hiển thị dự đoán bệnh từ BERT kèm câu trả lời/trích dẫn được truy xuất từ FAISS.



- Xây dựng giao diện web – trả lời câu hỏi



5. Phân tích ưu và nhược điểm của hệ thống BERT kết hợp FAISS

Kết hợp mô hình học sâu BERT với hệ thống truy xuất thông tin FAISS tạo nên một kiến trúc hiệu quả cho bài toán chatbot y tế. Thay vì chỉ dựa vào khả năng suy luận của mô hình, hệ thống tận dụng thêm cơ chế tìm kiếm ngữ nghĩa để cung cấp thông tin chính xác và phù hợp hơn. Phần này trình bày các ưu điểm nổi bật cũng như những hạn chế của phương pháp đề xuất.

5.1. Ưu điểm của hệ thống

Hệ thống kết hợp giữa BERT và FAISS mang lại nhiều lợi ích trong việc xử lý và trả lời câu hỏi y tế, đặc biệt trong bối cảnh dữ liệu chuyên ngành.

5.1.1. Tăng độ chính xác trong phân loại và truy xuất

Mô hình BERT có khả năng hiểu ngữ nghĩa của câu hỏi, từ đó dự đoán chính xác nhóm bệnh liên quan. Sau đó, FAISS hỗ trợ tìm kiếm các câu hỏi và câu trả lời tương tự dựa trên vector embedding.

Sự kết hợp này giúp:

- Xác định đúng ngữ cảnh câu hỏi
- Truy xuất thông tin phù hợp với nội dung đầu vào

- Hạn chế việc trả lời sai lệch

5.1.2. Tối ưu hiệu suất và tài nguyên tính toán

So với các mô hình ngôn ngữ lớn, việc sử dụng BERT đã được fine-tune giúp giảm đáng kể chi phí tính toán. Đồng thời, FAISS cho phép tìm kiếm nhanh trên không gian vector lớn, giúp hệ thống phản hồi trong thời gian ngắn.

- Hệ thống hoạt động nhanh
- Tiết kiệm tài nguyên
- Dễ triển khai thực tế

5.1.3. Khả năng mở rộng và cập nhật dữ liệu

Hệ thống cho phép cập nhật dữ liệu mới một cách linh hoạt mà không cần huấn luyện lại toàn bộ mô hình. Chỉ cần bổ sung dữ liệu vào kho và tạo lại vector embedding là có thể sử dụng ngay.

Ưu điểm này đặc biệt quan trọng trong lĩnh vực y tế, nơi thông tin liên tục thay đổi.

5.1.4. Cải thiện chất lượng câu trả lời

Thay vì chỉ đưa ra dự đoán bệnh, hệ thống còn cung cấp thêm các câu trả lời hoặc giải thích liên quan từ dữ liệu thực tế. Điều này giúp tăng tính hữu ích và độ tin cậy của hệ thống đối với người dùng.

5.2. Nhược điểm và thách thức

Dù hệ thống kết hợp giữa BERT và FAISS mang lại nhiều ưu điểm, việc triển khai thực tế vẫn tồn tại một số hạn chế và thách thức cần được xem xét kỹ lưỡng. Các vấn đề này chủ yếu liên quan đến chất lượng dữ liệu, khả năng của mô hình và hiệu quả của hệ thống truy xuất.

5.2.1. Phụ thuộc vào chất lượng dữ liệu

Hiệu suất của toàn bộ hệ thống phụ thuộc trực tiếp vào chất lượng của bộ dữ liệu huấn luyện và dữ liệu lưu trữ trong hệ thống FAISS. Nếu dữ liệu đầu vào chứa nhiều nhiễu, thiếu thông tin hoặc không chính xác, mô hình sẽ học sai hoặc không học được các đặc trưng quan trọng.

Ngoài ra, việc dữ liệu không cân bằng giữa các nhóm bệnh cũng có thể khiến mô hình thiên lệch (bias), dẫn đến dự đoán không chính xác ở các lớp có ít dữ liệu. Do đó, việc làm sạch, chuẩn hóa và lựa chọn dữ liệu đóng vai trò rất quan trọng trong toàn bộ hệ thống.

5.2.2. Hạn chế của mô hình BERT

Mặc dù BERT có khả năng hiểu ngữ nghĩa tốt, nhưng khi áp dụng vào lĩnh vực y tế – một lĩnh vực có nhiều thuật ngữ chuyên ngành phức tạp – mô hình có thể gặp khó khăn trong việc hiểu đầy đủ ngữ cảnh.

Một số hạn chế cụ thể:

- Khả năng suy luận logic còn hạn chế
- Khó xử lý các câu hỏi dài, phức tạp hoặc đa ý
- Phụ thuộc nhiều vào dữ liệu đã được huấn luyện

Mô hình chỉ dựa trên mẫu dữ liệu đã học mà chưa thực sự “hiểu sâu” về kiến thức y khoa.

5.2.3. Hiệu quả truy xuất phụ thuộc FAISS

Hệ thống FAISS hoạt động dựa trên vector embedding, do đó chất lượng của embedding ảnh hưởng trực tiếp đến kết quả tìm kiếm. Nếu vector không biểu diễn tốt ngữ nghĩa của câu hỏi, hệ thống có thể trả về các kết quả không liên quan.

Ngoài ra:

- Việc lựa chọn số lượng kết quả trả về (k) chưa phù hợp có thể làm giảm độ chính xác
- Dữ liệu chưa được chuẩn hóa tốt có thể gây sai lệch trong quá trình tìm kiếm
- FAISS chỉ dựa trên độ tương đồng vector nên không đảm bảo hiểu đúng ngữ cảnh hoàn toàn

Khiến hệ thống có nguy cơ cung cấp thông tin chưa thực sự phù hợp với câu hỏi của người dùng.

5.2.4. Thiếu khả năng sinh ngôn ngữ tự nhiên nâng cao

Hạn chế quan trọng của hệ thống là khả năng sinh ngôn ngữ tự nhiên còn hạn chế. Khác với các mô hình ngôn ngữ lớn (LLM) có khả năng tạo ra câu trả lời linh hoạt và mạch lạc, hệ thống hiện tại chủ yếu dựa vào việc truy xuất các câu trả lời có sẵn trong cơ sở dữ liệu thông qua FAISS.

Nội dung phản hồi thường mang tính “sao chép” hoặc trích xuất trực tiếp từ dữ liệu gốc, chưa có khả năng tổng hợp và diễn đạt lại thông tin theo ngữ cảnh cụ thể của người dùng. Điều này dẫn đến một số hạn chế như:

- Câu trả lời có thể thiếu sự liên kết, chưa thực sự mạch lạc
- Nội dung đôi khi không phù hợp hoàn toàn với cách đặt câu hỏi của người dùng
- Thiếu khả năng cá nhân hóa câu trả lời theo từng trường hợp cụ thể
- Khó xử lý các câu hỏi mở, yêu cầu giải thích chi tiết hoặc tư vấn chuyên sâu

Ngoài ra, hệ thống chưa có khả năng kết hợp nhiều nguồn thông tin để tạo ra một câu trả lời tổng hợp hoàn chỉnh, mà chỉ lựa chọn một số câu trả lời gần nhất về mặt ngữ nghĩa. Điều này có thể làm giảm chất lượng phản hồi trong những trường hợp cần phân tích đa chiều hoặc giải thích chuyên sâu.

Hạn chế này ảnh hưởng trực tiếp đến trải nghiệm người dùng, đặc biệt trong các ứng dụng thực tế, nơi người dùng kỳ vọng nhận được câu trả lời tự nhiên, dễ hiểu và mang tính tư vấn cao. Trong tương lai, hệ thống có thể được cải thiện bằng cách tích hợp thêm các mô hình sinh ngôn ngữ (LLM/SLM) để nâng cao khả năng diễn đạt và tổng hợp thông tin.

5.3. Bảng tổng kết đánh giá

Ưu điểm	Nhược điểm
Độ chính xác cao trong phân loại	Phụ thuộc vào chất lượng dữ liệu
Tốc độ xử lý nhanh	BERT có hạn chế về suy luận
Tiết kiệm tài nguyên	FAISS có thể truy xuất sai
Dễ mở rộng dữ liệu	Câu trả lời chưa tự nhiên
Kết hợp phân loại truy xuất hiện quả	Chưa có khả năng sinh văn bản mạch lạc

